

基于 RK3588 的能效标签检测系统

摘 要

针对家电生产线能效标签人工检测效率低、易出错及环境适应性不足等问题，本团队设计并实现了一套基于 RK3588 的嵌入式视觉检测系统。系统部署于飞凌 ELF2 开发平台，采用 Detector + Classifier 双模型级联架构：Detector 基于 YOLOv8n^[1,2] 实现标签定位，Classifier 基于 MobileNetV3 完成能效等级判定与缺陷分类（正常/划痕/污渍/褶皱），支持数据上传到本地上位机。

在图像预处理环节，系统通过软件的摄像头畸变矫正和图像增强有效补偿了产线环境下的采集模糊与噪声干扰；视觉算法设计为检测—裁剪扶正—分类—规则判断的多阶段链路，提出预存候选框、YOLO 检测器及轮廓提取的多源容错机制，并采用 MobileNetV3 Large 双头结构并行输出能效等级与缺陷类别，以几何规则判定位置合规性。

实验结果表明，该系统在正式测试集上端到端识别准确率达到 96.72%，缺陷识别率达到 93.32%，单帧处理时延满足产线实时性要求，有效解决了家电生产线能效标签检测的自动化替代难题，形成了从底层操作系统、边缘硬件平台到视觉算法部署的全链路自主可控技术方案，具备良好的工程推广价值与产业化应用前景。

关键词：RK3588；YOLOv8；MobileNetV3 Large；MQTT；工业质检

一、作品概述

1.1 功能与特性

当前家电行业的标签检测主要依赖人工抽检或传统的机器视觉手段。然而，随着混流生产的普及，标签种类日益多样化，传统方式在检测速度、复杂环境适应性以及准确率方面已难以满足现代化高速产线的需求。

本项目是一套面向工业产线的能效标签等级和缺陷的检测系统。系统通过 USB 摄像头或 CSI 摄像头获取 640×480 分辨率的 YUV 图像，经过 letterbox 和格式转换的预处理后，等待外部光电传感器的触发将 640×640 的 RGB 图像送给部署在本地的模型执行推理，采用 Detector+ Classifier 双模型级联架构：Detector 负责标签定位，Classifier 获取 Detector 的 BBox 裁剪出 320×320 的 RGB 图像作为输入，输出能效等级与缺陷类别。




图1 简易功能框图

嵌入式端程序基于 Qt 5 + QThread 多线程架构，支持 USB/CSI 摄像头一键切换、实时窗口预览+结果帧显示、历史数据回溯。系统配套提供 systemd 自启动服务，实现 GPIO 开机自动配置，满足产线无人值守需求。

系统支持端侧的数据记录，可通过 MQTT 协议将识别到的结果发送到处于同一局域网的 PC 端，实现上位机实时监控产线情况。当识别到带有缺陷的标签时，嵌入式端会蜂鸣器报警同时上位机端弹出红色报警信息。

1.2 应用领域

本项目主要应用于家电制造、照明与 LED 产业、消费电子以及更广泛的工业自动化与智能制造领域。在家电行业，适用于冰箱、空调、洗衣机等白色家电产品出厂前能效标识的自动化合规检测。在照明产业，面向灯具包装环节能效标签的缺陷筛查与位置偏移监控。消费电子领域则覆盖显示器、电脑等 IT 设备能效标识的质量把控。

同时，该项目属于嵌入式机器视觉与边缘计算范畴，适用于需要本地实时图像处理的智慧工厂场景。通过端侧 AI 推理实现产线末端的无人化质检，可作为数据采集终端接入制造执行系统，支持生产追溯与良率统计。整体面向对检测延迟敏感、需离线稳定运行的工业流水线环境，尤其适合包装工位或末端检测站的视觉质检部署。

1.3 主要技术特点

1.3.1 嵌入式多线程软件架构与双源采集

系统基于 Qt 5 构建嵌入式 GUI，摄像头采集与模型推理运行于独立 QThread，通过信号-槽跨线程通信，避免 NPU 推理阻塞界面。支持 USB 与 CSI 摄像头一键热切换，采集端通过 `cv::remap` 实时畸变矫正。检测历史以内存列表维护，支持表格化回溯。

1.3.2 双模型级联与 NPU 加速推理^[4]

Detector 采用 YOLOv8n 定位标签，用于标签识别（单类别检测）；Classifier 采用 MobileNetV3 Large 双头结构，同步输出 5 级能效与 4 类缺陷。推理基于 RKNN API 直接调用 RK3588 NPU，封装支持单/多输出模型自适应。分类前引入 letterbox 等比缩放、中值滤波降噪与 Unsharp Mask 锐化，增强小缺陷识别。

1.3.3 工业物联集成与产线联动

系统通过 GPIO 下降沿检测适配 PLC 外部触发，检测到缺陷时驱动蜂鸣器报警。推理结果通过 MQTT 异步上报，采用非阻塞连接、JSON 格式、5 s 心跳保活。同时计算检测框与图像中心偏移比率（阈值 15%），为产线装配精度提供量化反馈。

1.4 主要性能指标




图2 标签识别性能（左） 标签检测性能（右）

YOLOv8n 在正式 test 集上取得了较高的检测性能，其中 Precision 达到 99.93%，Recall 达到 100.00%，mAP@50 达到 99.50%，mAP@50:95 达到 99.08%

结果表明，系统能够较准确地完成能效标签区域定位，为后续等级识别、缺陷识别和位置判断提供稳定输入。

在完整模型组流程下，系统的整体能效等级识别准确率达到 96.72%，缺陷识别 Macro-F1 达到 93.32%，同时缺陷识别 Macro-Recall 达到 93.40%。

结果表明，当前方案在完成标签定位后，能够较稳定地实现等级判断与缺陷识别，具备较好的实际应用效果。

1.5 主要创新点

1.5.1 多源兜底的双模型级联架构

在检测与分类分离的两阶段链路基础上，构建多来源 BBox 获取机制（proposal_csv $\rightarrow$ YOLO_detector $\rightarrow$ propose_label_box）。当主检测器输出不稳定时，系统仍可从辅助来源获取有效候选框，避免任务中断，提升整条链路的鲁棒性与可用性。同时采用 MobileNetV3 双头分类器并行输出等级与缺陷，实现空间定位、语义分类与位置规则判断的三任务解耦。

1.5.2 基于颜色先验的标签姿态校准与规格化

针对检测粗框误差及标签姿态偏斜问题，构建几何规格化流程：对标签区域进行扩框裁剪，通过蓝色通道提取与轮廓分析精准识别标签主体，基于 minAreaRect + warpAffine 完成旋转校正，并经过二次紧裁剪剔除无关背景干扰，使分类模型接收更规整的输入，提升识别一致性与可靠性。

1.5.3 像素级与几何级协同的图像预处理

在几何规格化基础上，进一步采用中值滤波去除工业环境下的椒盐噪点，通过 Unsharp Mask 锐化增强文字与条纹边缘清晰度；同时以 letterbox 黑边填充替代直接 resize，保持标签原始宽高比，避免数据帧变形，从像素和几何两个维度保障模型输入质量。

二、系统架构

本项目的总体结构可分为三部分：部署端，模型端，硬件端，上位机端部署端主要涉及端侧的线程实现，包括但不限于图像的预处理、推理和后处理实现；模型端主要涉及模型训练的方案和核心逻辑；硬件端主要涉及摄像头设备参数、系统的扩展电路 PCB 设计以及适配工业场景的机械结构设计；上位机端主要介绍上位机的 UI 界面以及架构

2.1 部署端架构

部署端架构的框图如图所示，可分为五个方面：采集、预处理、推理、后处理、UI 设计、上位机上传。




图 3 系统总体框图-部署端

2.1.1 图像采集

本系统同时支持 CSI 和 USB 进行图像帧获取，可在 UI 界面进行切换，目前机械设计方面只做了 USB 摄像头的配置，摄像头采集 640x480 分辨率的图像，为保证推理结果精度，获取原始 YUV 图像数据，未经推理的图像预览界面显示在 UI 界面的左侧用于工业产线上带有能效标签的家电的位置标定。



图 4 UI 预览界面

2.1.2 图像帧预处理

端侧每隔 50ms 识别 GPIO 的逻辑电平，当出现下降沿时准备将获取的图像进行推理，为适配工业环境变化并保证推理的结果准确，对图像进行预处理：

（1）标定与预畸变矫正

未经过畸变矫正的摄像头会在边缘出现桶型畸变^[5]，会严重影响获取的图像帧质量，USB 摄像头的畸变较为严重，CSI 摄像头畸变较轻。标定后，摄像头可以用于精确的图像测量、三维重建或视觉任务。



图 5 有无畸变对比

以 USB 摄像头为例，采用张正友棋盘格标定法对摄像头进行标定，获取内参矩阵 K 与 5 维畸变系数 D 。标定过程使用 10×7 棋盘格，在 640×480 分辨率下采集 15~20 张不同角度/距离的标定板图像，借助 OpenCV 获取参数，本项目所用摄像头获取的参数如下：

参数	值	说明
重投影误差	0.297 像素	标定精度指标，<0.5 视为合格
焦距 f_x/f_y	302.70/302.20	水平/垂直焦距（像素单位）
主点 c_x/c_y	298.68/234.97	图像中心偏移
径向畸变 k_1/k_2	0.0616/0.0961	桶形畸变系数（正值）
切向畸变 p_1/p_2	0.0004/0.0009	镜头-传感器装配倾斜，接近 0
高阶径向 k_3	0.0253	三阶畸变修正量

表 1 标定参数

标定后的结果如图，可见能效标签的桶型形变消失，可做进一步处理：



图6 能效标签标定前与标定后

(2) 数据帧格式转换和分辨率调整

Detector (YOLOv8n) 模型要求的输入是 640×640 的 RGB 图像，需要先将获取到的 YUV2 图像转换为 RGB 图像，为防止能效标签形变拉伸，采用 Letterbox 将图片从 640×480 填充到 640×640 。

Letterbox（信箱模式）是一种保持原始画面宽高比的显示技术。当视频内容与播放设备比例不匹配时，系统在画面上下添加黑边填充多余空间，避免裁剪画面或拉伸变形。同理，窄屏内容在宽屏上播放时左右加黑边，称为 Pillarbox。Letterbox 的核心是用黑边换完整画面，确保导演意图不被破坏，广泛应用于电影播放、流媒体适配和游戏多分辨率兼容。



图7 letterbox 处理

(3) 图像锐化增强

工业产线环境多变，为了保证推理结果的准确性和稳定性，对进行畸变矫正的图片进行软件方面的图像增强，采用常用的 USM 锐化处理处理，将能效等级等细节特征变得清晰

Unsharp Mask（USM，非锐化掩模）是一种经典图像锐化算法^[6]。原理是对原图进行高斯模糊得到低频分量，用原图减去模糊图提取高频边缘细节，再将该细节按一定强度叠加回原图，从而拉大边缘对比度，使图像更清晰。通过调节模糊半径 Radius 控制边缘宽度，阈值过滤微小噪声。




图 8 USM 处理

原图和高斯模糊处理后 RGB 三通道的像素值进行线性计算，其权重 k 可根据实际产线环境动态调整：

$$res = (1 + k)org - k \times Gaus$$

2.1.3 调用模型推理

RK 系列芯片的端侧部署和运行主要借助的是瑞芯微提供的工具链进行模型转换，通过连接 librknnrt.so 动态库的 rknpu_api.h 调用 NPU 加速推理，获取的图像帧经过预处理后等待执行推理

（1）预加载模型

PC 端训练好的 detector.onnx 和 classifier.onnx 模型经过工具链转换成 detector.rknn 和 classifier.rknn，将转换好的模型部署在端侧某一文件夹内，打开模型文件读取模型获取模型数据。

（2）执行推理并返回原始数据

将预处理好的数据帧直接送给模型推理，推理得到的结果拷贝返回。

2.1.4 后处理

后处理的流程主要集中在第一个 YOLOv8n 模型的处理，其后处理流程遵循标准的 Ultralytics 库处理流程。




图 9 detector 后处理流程

(1) YOLOv8n——decoder 原始输出

RKNN 输出通常是 NCHW 格式，由于此模型做的是单类别识别，输出矩阵为[1,5,8400](一个类别,5个参数,8400个候选框),对5个的参数 $[c_x, c_y, w, h, rconf]$ 进行线性或非线性的放缩变换。

c_x 和 c_y 代表着的是 BBox（候选框）的中心点坐标， w 与 h 代表着的是 BBox 的高度和宽度，通过这四个参数映射出候选框的四个角的坐标，为后续 UI 界面的框选提供坐标。

$$x_{1/2} = c_x \mp 0.5w$$

$$y_{1/2} = c_y \mp 0.5h$$

原始输出的置信度的输出的定义域并不是[0,1],需要对原始置信度进行 σ 变换得到定义域为[0,1]的 $conf$ 。

$$conf = \frac{1}{1 + e^{-rconf}}$$

(2) YOLOv8n——置信度和面积过滤

由于工业产线的环境因素等影响，系统很有可能出现误检的行为，对候选框进行初步过滤，通过放缩后的置信度和 BBox 面积进行过滤，本项目设定面积低

于 30，置信度低于 0.5 的 BBox 滤除。

(3) YOLOv8n——置信度排序和 Top-K 截断

计算全部 8400 个候选框 NMS 的计算量很大，将 8400 个候选框进行置信度从大到小排序，选取前 60 个 BBox 作为后续候选框。

(4) YOLOv8n——NMS 非极大值抑制

NMS (Non-Maximum Suppression, 非极大值抑制) 是目标检测后处理中去除冗余框的算法^[1,3]。当模型对同一个目标输出多个重叠检测框时，NMS 按置信度排序，取最高置信度框为基准，计算它与剩余框的交并比 IoU。若 IoU 超过阈值，则视为检测到同一目标，将其抑制。重复此过程直到所有框处理完毕，最终只保留每个目标置信度最高的唯一检测框。




图 10 NMS 示意图

排好序剩下的候选框互相计算交并比，阈值 IOU=0.5，角逐出最终候选框：

$$IOU = \frac{inter}{area_1 + area_2 - inter}$$

(5) Letterbox 反算和 classifier 输入的预处理

Detector 的输出的体现要在 UI 界面的右侧结果图实现框选，需要将结果 BBox 坐标反算成原始分辨率，同时，第二个模型要求输入 320×320 的 RGB 图像，以第一个模型的输出数据为准，依据 BBox 裁剪出 320×320 的区域作为 classifier 输入，同时，若裁剪得到的标签图像有所角度偏移，还会做适当的旋转。

(6) MobileNetV3——最大值索引映射

Classifier 的输出是双头输出[1,5]和[1,4]，其中第一个输出头为各等级的置信度，排序选出具有最大值的索引，映射到实际等级（0~4 映射到等级 1~5）；第二个输出头输出的是缺陷类别（正常，破损，褶皱，污渍），其处理方法同理。

关于是否偏移的判断，计算 BBox 中心点坐标和原始图像的中心点坐标的偏移程度：

$$offsetRadioX = \frac{(boxCenterX - imgCenterX)}{640}$$

$$offsetRadioY = \frac{(boxCenterY - imgCenterY)}{480}$$

只要 X 和 Y 坐标任意一个偏移值大于 15%，就证明其是偏移的，布尔函数 position_OK 就输出 false。

2.1.5 UI 设计


本项目采用 Qt 进行 UI 设计，嵌入式端的 UI 界面如下：



图 11 UI 界面

左上方用于显示实时预览的 FPS，左侧的 UI 预览用于工业产线上带有能效标签的家电的位置标定，其下方输出推理得到的结果：能效等级、缺陷类别、是否偏移；右侧显示推理的结果图，本项目应用的场景对于实时推理的要求并不高，

采用光电触发推理，光电传感器触发一次就推理一次，其下方提供摄像头切换和历史记录回溯功能，历史数据记录以弹窗的形式出现：



ID	时间	等级	缺陷	偏移
1 1	2026-07-07 ...	1	stain	是
2 2	2026-07-07 ...	1	damage	是
3 3	2026-07-07 ...	1	normal	否
4 4	2026-07-07 ...	1	stain	是
5 5	2026-07-07 ...	1	stain	否
6 6	2026-07-07 ...	1	stain	否
7 7	2026-07-07 ...	1	stain	否
8 8	2026-07-07 ...	1	damage	是
9 9	2026-07-07 ...	1	damage	否

图 12 历史记录回溯

2.1.6 MQTT 发送端

在推理线程中，端侧会在后处理结束后将推理得到的结果通过 MQTT 协议以 JSON 格式发送^[7]，定义发送的 JSON 为：设备名称+日期+检测序号 ID+能效等级+缺陷类别+偏移判断。传输方式为 MQTT Publish，Topic 为 ipc/detection/{device_id}，支持多设备发送，每台设备通过 device_id 区分。

2.2 模型端架构

2.2.1 候选框获取模块设计

本候选框获取模块用于在整幅图像中确定能效标签所在区域，是后续标签裁剪、分类识别和位置判断的基础。本系统在训练与推理流程中采用多源候选框获取机制，优先级依次为：预存标注框、YOLOv8n 检测器、规则提框以及中心框兜底。

在提供 proposal_csv 且当前图像路径能够命中时，系统优先使用预存候选框，以保证训练裁剪阶段输入区域的稳定性，并减少不必要的检测前向计算。当未命中预存框时，系统调用 YOLOv8n 检测模型进行能效标签定位。检测模型采用

单类别 label 训练，用于判断能效标签在原始图像中的位置。Python 推理阶段设置置信度阈值 $\text{conf}=0.25$ ，NMS 阈值 $\text{iou}=0.5$ ，并取检测结果中的首个有效框作为标签候选区域。

当检测器未加载或未返回有效检测框时，系统进入规则提框模块。规则提框基于能效标签主体颜色特征，在 HSV 色彩空间内使用阈值 $[90,40,40]$ 至 $[140,255,255]$ 提取蓝色区域轮廓，并根据最大有效轮廓计算标签边界框。若规则提框仍然失败，则使用归一化中心 $[0.5,0.5]$ 、尺寸 $[0.26,0.55]$ 的中心框作为兜底候选框，保证后续裁剪与分类链路不中断。




图 13 候选框获取

2.2.2 标签裁剪与扶正模块设计

由于检测模型输出的边界框通常包含一定背景冗余，且真实工业场景下标签可能存在轻微旋转、倾斜和透视变化，系统在候选框获取模块和分类模型之间设计了标签裁剪与扶正模块，用于提升分类输入区域的稳定性。

首先，系统根据候选框坐标从原图中裁剪能效标签区域。为了避免检测框过紧导致标签边缘信息缺失，裁剪前按照 $\text{padding_ratio}=0.05$ 对原始检测框进行适当扩展。随后，系统将裁剪图像转换至 HSV 空间，提取蓝色区域 mask，并寻找主要轮廓。当存在有效轮廓时，使用 `cv2.minAreaRect()` 计算最小外接旋转矩形，估计标签区域的旋转角度，并通过仿射变换完成旋转校正。

旋转校正后，系统再次对图像进行蓝色区域提取，并根据新的有效轮廓执行

二次紧裁剪，使分类模型输入尽可能聚焦于标签主体区域。若某一级处理失败，则逐级回退至扩框裁剪图或旋转图像，确保分类模型始终能够获得可用输入。通过该模块，系统能够降低背景、边缘冗余和轻微姿态变化对分类结果的影响。




图 14 标签裁剪和扶正模块

2.2.3 分类与位置判定模块设计

分类模型采用 MobileNetV3MultiTask 多任务结构，主干网络为 MobileNetV3 Large。模型共享前端特征提取网络，并在高层特征后并行接入两个分类头：grade_head 和 defect_head。其中，grade_head 输出 5 维 logits，对应能效等级 1、2、3、4、5；defect_head 输出 4 维 logits，对应 normal、damage、stain、wrinkle 四类标签状态。misaligned 不作为缺陷分类头的训练类别，而是由后续位置规则模块独立判断。

分类模型输入尺寸为 [1,3,320,320]。输入预处理流程包括：BGR 转 RGB、resize 至 320×320、转换为 float32、除以 255.0 进行归一化、按照 ImageNet 均值 [0.485,0.456,0.406] 和标准差 [0.229,0.224,0.225] 进行标准化，并将 HWC 格式转换为 CHW 格式后扩展 batch 维度。该预处理流程与模型导出和部署侧输入要求保持一致，有助于减少训练端与部署端之间的输入分布差异。




图 15 分类与位置判定

位置合规性由独立的几何规则模块完成，不额外训练位置分类模型。系统根据标签检测框中心点与图像参考中心之间的归一化偏移量判断贴附位置是否合规。当横向偏移量和纵向偏移量的绝对值均不超过 0.08 时，判定标签位置正常；否则判定为位置偏移，即 *misaligned*。该方法计算开销小、可解释性强，适合在端侧推理后处理中实时执行。

2.2.4 数据集构建与训练策略

本系统使用 *metadata.csv* 统一管理图像路径、能效等级、缺陷类别、数据划分以及是否参与分类器训练等信息。全量样本共 1429 张，按照 *train/val/test* 划分为 745/342/342。由于 *misaligned* 表示标签贴附位置异常，不属于分类模型缺陷头的语义类别，因此该类样本不参与缺陷分类头训练，而是用于位置规则判断与端到端流程验证。分类器有效样本共 1318 张，其中 *train/val/test* 划分为 687/326/305；能效等级 1 至 5 级的样本分布分别为 271、258、259、262、268；缺陷类别分布为 *normal* 798、*damage* 185、*stain* 169、*wrinkle* 166。

检测模型训练标注来自人工修正后的标签框文件 *corrected_bboxes.csv*，共 560 张图像，按照 *train/val/test* 划分为 392/84/84。检测类别为单类别 *label*，标注格式转换后用于 YOLOv8n 训练。检测器基于 YOLOv8n 预训练权重训练，输入尺寸为 640×640 ，训练 80 epoch，batch size 为 16，初始学习率为 0.01，权重衰减为 0.0005，优化器配置为 *auto*。检测增强沿用 Ultralytics 框架配置，包括 HSV 颜色扰动、平移、缩放、水平翻转、*mosaic* 和随机擦除等策略，其中关键参数包括 *hsv_h*=0.015、*hsv_s*=0.7、*hsv_v*=0.4、*translate*=0.1、*scale*=0.5、

fliplr=0.5、mosaic=1.0、erasing=0.4。

分类器训练 30 epoch，batch size 为 16，采用 AdamW 优化器，初始学习率为 0.0003，权重衰减为 0.0001，并使用 CosineAnnealingLR 学习率调度策略。模型 dropout 设置为 0.2，主干网络使用 MobileNetV3 Large 预训练权重初始化。损失函数方面，能效等级分类头采用 CrossEntropyLoss，缺陷分类头采用带类别权重的 CrossEntropyLoss，两个任务的损失权重均为 1.0。为缓解缺陷类别样本不均衡问题，训练过程中按照 defect 类别启用 WeightedRandomSampler 进行均衡采样。

数据增强方面，分类模型采用 Albumentations 实现 RandomBrightnessContrast、GaussianBlur、ShiftScaleRotate、Perspective、HueSaturationValue、CoarseDropout、Resize 和 Normalize 等操作，用于模拟工业场景中的光照变化、轻微模糊、角度偏移、透视变化和局部遮挡。通过上述训练策略，模型能够在较小规模数据集上提升对不同能效等级、缺陷状态和复杂拍摄条件的适应能力。

模型导出方面，训练端已完成检测模型和分类模型的 ONNX 导出。检测模型 ONNX 输入为 [1,3,640,640]，输出为 [1,5,8400]，导出时 nms=false，因此部署侧需要完成候选框解码、置信度筛选、非极大值抑制以及坐标映射。分类模型 ONNX 输入为 [1,3,320,320]，输出分别对应能效等级 logits 和缺陷类别 logits。训练端输出的 ONNX 模型作为后续 RKNN 部署转换的中间模型，为 RK3588 端侧推理服务提供模型基础




图 16 数据集构建与训练策略

2.3 硬件端架构

2.3.1 外设参数和性能

采集端采用的摄像头为轮趣科技的 C70-USB 摄像头或 OV13855-CSI 摄像头，其中具体参数如下表：




图 17 C70 结构尺寸图（左） OV13855 图（右）

参数	规格
型号	WHEELTEC C70
成像器件	1/4 CMOS
有效像素	100 万像素
感光面积	3.0UM×3.0UM
图像帧率	CIF:1-4 路 30 帧实时
接口类型	USB2.0
AGC	Auto
信噪比	大于 48dB
图片输出格式	YUY/MJPEG
最高分辨率	1280×720
视场角度	H85° V47°

表 2-1 C70 摄像头部分参数

参数	规格
型号	OV13855
有效像素	1300 万像素（4224×3136）
光学尺寸	1/3.06 英寸
像素尺寸	1.12 μm × 1.12 μm
帧率	13MP@30fps / 1080p@60fps
输出格式	10-bit RGB RAW
输出接口	MIPI CSI-2（1/2/4 lane）
动态范围	65 dB
信噪比	36.5 dB
CRA	33.15°

表 2-2 OV13855 摄像头部分参数

光电传感器采用大伟电器的漫反射光电开关 E18-D80NK2，其参数如下表：

参数	规格
型号	E18-D80NK2（NPN 常闭）
类型	漫反射型光电开关
工作电压	DC 5v
感应距离	3~77cm
响应时间	<2 ms
光源类型	红外发光（950nm）
扩散角度	3~5°
输出最大电流	300 mA
消耗电流	≤ 20~35 mA（无负荷）
工作温度	-25~80° C

表 3 E18-D80NK2 部分参数

使用的端侧主平台为 RK3588-elf2，其最主要有 6TOPS 算力的三核 NPU 以及 USB2.0 接口，支持本项目双模型的低时延推理和 USB 摄像头驱动。

2.3.2 PCB 设计

端侧系统是通过读取光电传感器传给 GPIO 的开关信号来判断是否出现外部触发的，同时，当识别到有缺陷的标签时要出发蜂鸣器报警，某一 GPIO 要高电平置位，需要设计 PCB 板提供接口，考虑到机械外观设计，PCB 的 layout 尽量紧凑，PCB 原理图设计如图所示：




图 18 PCB 原理图

由于赛题要求，并没有在主开发平台的硬件设计上做文章，只做了简单的扩展电路，主要分为三部分：为 GPIO 输出提供的蜂鸣器电路、光电传感器电路、连接开发板的 2*10pin 接口。

本项目选取 ELF2-RK3588 开发板的 20PIN 排针接口作为连接接口，选取 GPIO3_C4(GPIO116)作为蜂鸣器控制接口，配置成输出模式，蜂鸣器驱动需要大电流，通过 GPIO 控制三极管开关来驱动 5v 蜂鸣器。

选取 GPIO4_B3(GPIO139)作为光电触发接口，配置成输入模式，通过一级 LM358 运放将光电传感器信号端的微弱信号放大到 5v 电源轨附件，后续的中值比较器以 2.5v 为基准可以将输出的逻辑电平反相（0->4.5v，4.5v->0），可以通过跳线帽决定是否启用便于后续调试，为防止光电开关的干扰倒灌进开发板，采用光耦进行隔离。

PCB 为简单的双层板设计，版图如下所示：




图 18 顶层版图（左） 底层版图（右）

Layout 和布线较为简单，注意模拟地和数字地隔离以及光电开关焊盘的放置。

2.3.3 机械外观设计

面度工业产线场景，可能存在外界灰尘等的干扰，为主平台搭建外壳进行保护，为屏幕搭建支架方便观察。




图 19 外壳设计（左） 支架设计（右）

为模拟实际的产线环境，本项目搭建出一条传送带系统，为摄像头和光电开关提供物理支架：



图 20 传送带系统

2.4 上位机端架构

部署端的数据会通过 MQTT 协议将数据传送给处于同一局域网下的 PC 机，PC 机打开上位机程序即可实时监测产线的情况。




图 21 上位机系统框图

2.4.1 表现层

表现层基于 PyQt6 构建，采用单窗口多页面导航模式。主要页面包括：实时监视为核心的首页 Dashboard、历史查询页、报警记录页、设备管理页和系统设置页。各页面通过自定义导航按钮切换，UI 风格统一，支持高 DPI 适配。首页实时展示检测总数、良品数、NG 数及良品率趋势图，报警区域采用红色高亮提示，支持一键确认。

2.4.2 业务逻辑层

业务逻辑层是上位机的中枢调度模块，包含 MQTT 消息处理器、报警管理器、数据缓存器和定时刷新器。该层负责接收下位机上报数据、解析 JSON 协议、执行 NG 判定逻辑、触发红色警示，并将数据分发到 UI 层和数据库层。其中 NG 判定规则为：缺陷类型非 normal，或 position_ok 为 false 时判定为 NG。

2.4.3 数据访问层

数据访问层使用 SQLite 单例模式，启用 WAL 预写日志提升并发性能。核心数据表包括检测结果表、设备信息表和报警记录表。提供封装好的 CRUD 接口，支持按时间范围、设备 ID、缺陷类型、NG 状态等多维度查询。

2.4.4 通信层

通信层基于 paho-mqtt 实现，兼容 1.x 和 2.x 版本，具备自动重连、断线检测和消息去重机制。上位机启动时自动检测是否有 mosquitto broker 存在，若没有则要求用户提供本地 mosquitto.exe 路径，自动配置服务并启动，退出时保持 broke 运行以确保开发板连接不中断。支持多设备同时接入，通过 ipc/detection/{device_id} 主题区分不同设备来源。




图 22 自动配置服务

2.4.5 配置层

配置层采用 JSON 文件持久化，管理 MQTT 连接参数、报警阈值、UI 主题、默认导出路径等配置项。支持运行时热加载，配置变更无需重启程序。

三、完成情况及性能参数

本项目为模拟工业流水线场景，搭建了一套基于传送带的系统，系统整体如图所示：




图 23 系统整体外观图

本系统主要分为三个部分：第一张图片左下角的嵌入式部分，作为端侧等待触发信号执行推理；第一张图片右边的PC 端上位机，在同一局域网下通过 MQTT 接收来自嵌入式端的推理结果并做相应显示；第二张图片的产线部分，模拟实际工业产线环境搭建的传送带系统，配置有为采集端提供物理支撑的支架以及物理

固定提供外部触发信号的光电传感器。

3.1 工程成果

3.1.1 机械成果

机械外壳和支架物理实物如图所示：



图 24 物理外观图

3.1.2 电路成果

其内部的结构如图所示，扩展板直插在 ELF2 开发板的 20PIN 排针接口上，光电传感器和天线由外壳的圆形口引出：




图 24 内部图

3.1.3 软件成果

上位机界面的 UI 主界面如下图所示，支持数据的统计分析、历史数据查询、多设备管理，嵌入式端的 UI 界面前文已经提交不做展示。




图 25 上位机 UI 主界面图

历史记录会保存在数据库中，可以选择将历史记录导出成 CSV 文件。

3.2 特性成果

以能效等级 1 缺陷为破损为例，检测结果界面如图所示：




图 26 端侧单次测量结果图

左边部分用于实时预览标定位置，右侧显示出推理得到的画框结果图，右下角也显示出当前结果，任意选取非训练集的标签图片进行端侧结果测试，数据如下表：

测试标签	理论值			实际值		
	能效等级	破损类别	位置	能效等级	破损类别	位置
1	1	正常	正常	1	正常	正常
2	4	污渍	正常	4	污渍	正常
3	3	正常	正常	3	正常	正常
4	1	污渍	正常	1	污渍	正常
5	2	破损	正常	2	破损	正常
6	5	破损	正常	5	破损	正常
7	1	破损	正常	1	破损	正常
8	1	褶皱	偏移	1	褶皱	偏移
9	2	正常	正常	2	正常	正常
10	4	正常	偏移	4	正常	偏移

表 4 测试结果

可见测试结果正常，缺陷类别和标签位置的判断正确，每次检测的结果会以 JSON 形式保存，每一条信息包括但不限于 ID+时间+缺陷类别+能效等级，检测的记录如下图：



推理数据回溯

ID	时间	等级	缺陷	偏移
1 1	2026-07-07 ...	1	stain	是
2 2	2026-07-07 ...	1	damage	是
3 3	2026-07-07 ...	1	normal	否
4 4	2026-07-07 ...	1	stain	是
5 5	2026-07-07 ...	1	stain	否
6 6	2026-07-07 ...	1	stain	否
7 7	2026-07-07 ...	1	stain	否
8 8	2026-07-07 ...	1	damage	是
9 9	2026-07-07 ...	1	damage	否

图 27 数据记录弹窗

四、总结与期望

4.1 可扩展之处

4.1.1 硬件端

遗憾的是，由于外壳设计原因以及 ELF2 配套 CSI 摄像头 FPC 软排线太短，目前的 CSI 摄像头采集物理设计并不完善，同时外壳没有做到较为良好的散热，未来会将外壳改为 CNC 金属并加上散热接口，为 CSI 摄像头设计扩展板以延长其物理距离。

同时，对于数据帧的获取，本项目的 USB 摄像头像素过低，且没有硬件补光，未来将采用更高像素的 USB 摄像头并做出补光灯扩展电路。

4.1.2 UI 界面美化

出于实用性考虑，嵌入式端的 UI 界面并没有做过多美化，未来可为其 UI 界面做一定的美化。

4.1.3 模型选择

YOLOv8+MobileNetv3 选择是出于其生态的考虑，网上开源资料多，简化了模型训练的时间成本，未来可选择更为先进的模型架构。

4.2 心得体会

4.2.1 部署端、硬件端、上位机端

本项目以 RK3588 边缘计算平台为核心，构建了一套完整的工业视觉检测系统。在硬件选型和系统集成层面，最大的体会是：嵌入式系统的复杂度不在单点，而在接口之间的衔接。

(1) 硬件端

RK3588 的 NPU 提供了 6TOPS 算力，足以支撑 YOLOv8n 与 MobileNetV3 的双模型级联推理，但其价值只有在内存带宽、摄像头接口、GPIO 中断协同工作时才能释放。我们在实践中发现，USB 摄像头的采集格式选择（YUYV vs MJPEG）直接影响后续分类模型的输入质量——MJPEG 的有损压缩会抹掉文字边缘的高频细节，导致细粒度缺陷难以区分。此外，手动关闭 V4L2 自动曝光、固定曝光值，是消除传送带运动拖影的关键，这一步往往被软件开发者忽视，却是产线部署的硬性要求。GPIO 硬件联动是本系统的另一核心。光电传感器接入 GPIO139 实现下降沿触发，蜂鸣器由 GPIO116 驱动报警。这里的技术要点在于“硬实时”与“软延时”的分离：光电触发和蜂鸣器控制必须走 GPIO 硬输出，响应在毫秒级；而 MQTT 数据上报走异步网络，允许百毫秒级延迟。如果混淆这两类时序要求（例如用软件定时器模拟蜂鸣器），会导致报警延迟不可控，失去产线即时拦截的意义。

(2) 部署端

Qt 5 多线程架构承担了采集、推理、UI 三线分离的职责。CameraThread 与 InferenceThread 运行于独立 QThread，避免 NPU 推理阻塞界面刷新。RKNN 模型的集成过程中，我们深刻体会到训练完成只走了 70% 的路——从 PyTorch 到 ONNX 再到 RKNN，每一步都可能引入精度损失。特别是 RKNN 的 `config(mean_values, std_values)` 将归一化 bake 进模型后，端侧若重复做/255 或 mean/std 处理，输入会被二次缩放，结果完全失真。systemd 自启动服务的配置，则是实现产线无人值守的最后一块拼图。

(3) 上位机

上位机端基于 PyQt6 开发了监控管理软件，负责 MQTT Broker 自动启动、实时看板展示、数据库存储与 CSV/Excel 导出。上位机与端侧之间通过 MQTT（QoS=1）异步通信，心跳保活机制确保了设备在线状态的可感知性。在实际联调中，我们发现网络抖动不会导致检测中断——这是异步架构的优势，也是工业现场必须具备的容错能力。

4.2.2 模型训练端

模型训练是本项目的底层支撑，也是误差最容易被放大传递的环节。

我们采用 YOLOv8n + MobileNetV3-Large 双头分类的级联架构。这一选择出于务实考量：端到端单模型虽然简洁，但在有限算力与数据量约束下，多任务头的收敛困难和类别不平衡问题突出。双模型级联实现了检测与分类的任务解耦，两个模型可以独立优化、各自专注单一任务，且均可在 RK3588 高效运行。但级联架构不可避免地引入了误差传递风险——Detector 的框偏或漏检会直接传导至下游分类器。为此，我们在推理阶段以 BBox 中心裁切 320×320 区域时保留一定边距，同时通过位置偏移检测对定位质量进行量化反馈，超出阈值的检测结果标注为位置异常，避免错误分类结果被采信。

训练过程中最深刻的教训是数据分布一致性。Classifier 在实验室测试精度达 92% 以上，但部署到产线后，斜拍视角与反光背景导致识别率显著下降。根本原因在于训练数据未能覆盖产线真实环境的多样性。更隐蔽的问题是预处理 pipeline 的错位：训练时采用了“蓝色标签矫正 → resize → 归一化”的标准流程，而早期部署端用 letterbox 或直接 resize 替代，导致输入分布偏移。这让我们意识到，在工业视觉中，预处理不是“可有可无的细节”，而是模型泛化能力的第一道防线。

向 RKNN 迁移时，INT8 量化曾导致 Classifier 输出维度从 9 维压缩至 5 维，缺陷分类头直接丢失，最终不得不退回 FP16。这一经历表明，端侧部署约束应在训练早期就被纳入设计，而非事后补救。

五、参考文献

- [1] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLOv8[Z]. 2023.
- [2] HOWARD A, SANDLER M, CHU G, et al. Searching for MobileNetV3[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1314-1324.
- [3] NEUBECK A, GOOL L V. Efficient non-maximum suppression[C]//18th International Conference on Pattern Recognition. 2006: 850-855.

- [4] 瑞芯微. RK3588 技术参考手册与 RKNN SDK 用户手册[EB/OL]. 2022-2023.
- [5] ZHANG Z. A flexible new technique for camera calibration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.
- [6] GONZALEZ R C, WOODS R E. Digital image processing (4th ed.)[M]. New York: Pearson, 2018.
- [7] BANKS A, GUPTA R. MQTT version 3.1.1[EB/OL]. OASIS Standard, 2014.